

Veri Hazırlama, Özellik Mühendisliği ve Model Keşfi

Gelecekte satın alma hareketsizliği için yeniden üretilebilir zamansal müşteri modellemesi

Ders: Samsung Innovation Campus — Pazarlamada Yapay Zekâ Bitirme Projesi

Ekip: Grup 7

Proje: GrowthPilot AI

Hazırlayan: Şahin Başcı

Tarih: 9 Eylül 2026

Durum: Nihai yerel akademik paket

YAPAY ZEKA KULLANIM BEYANI — Bu belge OpenAI Codex/ChatGPT desteğiyle hazırlanmış ve depo kanıtlarıyla kontrol edilmiştir. Proje ölçütleri yürütülmüş, sürümlenmiş eserlerden gelir; dış iddialar kaynaklandırılmıştır. İnsan incelemesi gereklidir.

Bölüm I — Veri hazırlama ve özellik mühendisliği

1. Genel bakış ve toplama

İşlem hattı UCI Online Retail II'yi kalıcı depo URL'sinden indirir, SHA-256 572e36277c2390fbfde10664750731e0a86f55e33470d91919085f0408e67bfb değerini doğrular, iki çalışma sayfasını profiller ve belirlenimci raporlar yazar. Ham ve müşteri düzeyi hazırlanmış dosyalar yerelde/Git dışında; toplu kanıtlar ve betikler sürüm denetimindedir.

2. Temizleme ve doğrulama

Adım	Satır / kural	Gerekeçe
Ham girdi	1.067.371	Dış kaynak kanıtı korunur
Birebir yinelenenleri kaldırma	34.335 kaldırıldı	Aynı işlem satırının tekrarını önler
Kimlik/tarih kullanılabilirliği	235.151 dışlandı	Anlık görüntü için kararlı kimlik ve zaman gerekir
Tutulan normalleştirilmiş satır	797.885	Belirlenimci kurallar sonrası standart ad/tür
Uygun satın alma olayı	Pozitif miktar/fiyat; iptal değil; kesim öncesi	Satın almayı iade/iptalden ayırır

Kanıt sınıfı: artifacts/reports/data_preparation.json üzerinden projede üretilmiştir.


Eksik müşteri kimliği atanmamıştır; keyfi atama sahte geçmiş üretti. Eksik açıklamalar müşteri davranış özelliklerini engellemez. Pozitif olmayan miktar/fiyat ve iptal faturaları uygun olaylardan çıkarılır ancak kaynak kalite kanıtında kalır. Parasal aykırı değerler toplama öncesi kırılmaz; log1p ve standartlaştırma eğitilmiş hat içinde ölçek baskısını azaltır.

3. Zamansal anlık görüntüler ve sızıntı önleme


Veri bölümü	Kesim tarihleri	Satır	Hareketsizlik oranı
Eğitim	2010-06-01-2010-12-01 aylık	20.677	0.483823
Doğrulama	2011-03-01	3.349	0.577187
Kalibrasyon	2011-06-01	2.659	0.499436
Nihai test	2011-09-01	2.772	Nihai değerlendirmeye kadar mühürlü

Tüm özellikler kesinlikle kesim öncesi olayları kullanır; her 90 günlük etiket penceresi tamamen gözlenir.

4. Keşifsel veri analizi



Şekil 1. Eğitim anlık görüntülerinde etiket yaygınlığı ve yakınlık.



Şekil 2. Sıklık ve harcama dağılımları dönüşümlü modellemeyi destekler.

Eğitim 20.677 müşteri anlık görüntüsü ve %48,3823 hareketsizlik etiketi; doğrulama 3.349 satır ve %57,7187 hareketsizlik içerir. Yaygınlık değişimi doğruluğun neden birincil ölçüt olmadığını gösterir. Çarpıklık ve tekrarlı gözlemler, rastgele satır bölmesi yerine zamana dayalı değerlendirme ve müşteri davranışı toplamalarını destekler.

5. Özellik tasarımı

Özellik ailesi	Örnekler	Gerekçe
Yakınlık/müşteri yaşı	recency_days, tenure_days	İlişkinin ne kadar yakın ve eski olduğu
Sıklık/ritim	invoice_count, active_days, ortalama/medyan/azami aralık	Tekrar ve satın alma dönemselliği
Parasal	brüt/net harcama, ortalama sipariş, iade	Ticari büyüklük ve ters işlem
Ürün çeşitliliği	farklı ürün, miktar, sepet genişliği	Etkileşim derinliği ve çeşitliliği

Özellik ailesi	Örnekler	Gerekçe
Pencereli davranış	30/60/90 günlük sayım/harcama ve eğilim	Kesim öncesi hızlanma veya düşüş
Bağlam	ülke ve anlık görüntü ayı	Hat içinde kodlanan pazar/zaman bağlamı

6. Ölçekleme, normalleştirme ve kodlama

scikit-learn ColumnTransformer ön işlemeyi yalnız eğitim verisinde uyarlar. Sayısal sütunlar medyan doldurma, uygun yerde log1p ve lojistik regresyon için StandardScaler kullanır. Kategorikler en sık değerle doldurulur ve bilinmeyen kategori toleranslı one-hot kodlanır. Ağaç adayları, ölçeklemenin ağaçları iyileştirdiğini varsaymadan uyumlu kodlanmış girdi kullanır.

```
numeric = Pipeline([
    ('impute', SimpleImputer(strategy='median')),
    ('scale', StandardScaler()),
])
categorical = Pipeline([
    ('impute', SimpleImputer(strategy='most_frequent')),
    ('onehot', OneHotEncoder(handle_unknown='ignore')),
])
model = Pipeline([('preprocess', ColumnTransformer(...)),
    ('classifier', LogisticRegression(C=0.01, max_iter=2000))])
```

Bölüm II — Model keşfi

1. Aday seçimi gerekçesi

Yakınlık sezgiseli iş temeli; kukla önsel, modelin sıralama bilgisi katıp katmadığı kontrolüdür. Lojistik regresyon şeffaf, hızlı ve düzenlenebilir; rastgele orman doğrusal olmayan etkileşimleri; LightGBM verimli artırılmış ağaç yaklaşımını temsil eder. Kavram sunumu LightGBM öngörse de deney ona öncelik vermemiş, doğrulama PR-AUC lojistik regresyonu seçmiştir.

Aday	Güçlü yön	Zayıf yön
Yakınlık sezgiseli	Basit ve açıklanabilir	Sıklık, değer ve ritmi yok sayar
Kukla önsel	Kalibrasyon/yaygınlık sağlaması	Kişiselleştirilmiş sıralama yok
Lojistik regresyon	Şeffaf, verimli, kararlı düzenleme	Doğrusal log-olasılık sınırı
Rastgele orman	Doğrusal olmayan etkileşim ve sağlamlık	Daha büyük model; kalibrasyon bozulabilir
LightGBM	Güçlü doğrusal olmayan tablo öğrenicisi	Daha karmaşık ayar/yorum ve aşırı uyum riski

2. Eğitim, hiperparametreler ve doğrulama

Adaylar test öncesi yedi kesimde eğitilir. Aile, yalnız 2011-03-01 doğrulamasında seçilir. 2011-06-01 sigmoid kalibrasyon ve eşik için ayrılır; 2011-09-01 keşifte kullanılmaz.

Model	Temel parametre	Doğrulama PR-AUC	ROC-AUC	Brier	İlk %10 artış
Yakınlık	clip(recency/180)	0.715529	0.689417	0.248166	1.292940
Kukla	prior	0.577187	0.500000	0.244072	0.961948
Lojistik	C=1.0	0.805322	0.782819	0.213300	1.510154
Rastgele orman	300 ağaç; yaprak=10	0.803517	0.782053	0.195463	1.520498
LightGBM	300 ağaç; lr=.05; yaprak=31	0.805223	0.776941	0.200875	1.546357

Seçim ölçütü doğrulama PR-AUC; ilk kazanan lojistik regresyondur. Nihai test matrisi ve eğrileri sızıntıyı önlemek için keşifte üretilmemiş, test açıldıktan sonra Rapor 04'te sunulmuştur.

3. Değerlendirme yorumu

Lojistik PR-AUC 0.805322, LightGBM 0.805223 ve rastgele orman 0.803517 değerlerini az farkla aşar. Ağaçların kalibre edilmemiş Brier değerleri daha iyidir; bu, sonuç gördükten sonra seçim ölçütünü değiştirmeyi değil ayrı kalibrasyonu gerektirir. Yakınlık temeli daha zayıf ama anlamlıdır.

4. Yeniden üretilebilirlik

```
make data-download
make data-profile
make data-prepare
make features-build
make train
# Çıktılar bölme özetlerini, MLflow kimliklerini, parametreleri ve ölçütleri içerir.
```

Her bölüm SHA-256, hedef/özellik/bölme sürümleriyle izlenir; MLflow çalıştırmaları kaydeder. model_exploration.json içindeki final_test bayrağının false olması keşfin nihai testten önce tamamlandığını gösterir.

5. Sonuç

Hazırlık hattı sızıntıya dayanıklı ve belirlenimcidir. İlk keşif iyileştirme için lojistik regresyonu seçmiştir. Sonuç belirtilen tarih ve ölçütle sınırlıdır; evrensel üstünlük veya üretim hazırlığı iddiası değildir.

Kaynakça

Chen, D. (2012). Online Retail II [Veri kümesi]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5CG6D>

scikit-learn geliştiricileri. Model değerlendirme, ön işleme ve olasılık kalibrasyonu belgeleri. <https://scikit-learn.org/stable/>

Ke, G., et al. (2017). LightGBM: A highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems, 30.

Proje kanıtları: artifacts/reports/dataset_profile.json, artifacts/reports/data_preparation.json, artifacts/eda, artifacts/ml/model_exploration.json ve ilgili betikler/testler.