

Model İyileştirme ve Test Çalışması

Dondurulmuş, kalibre edilmiş lojistik müşteri kaybı vekil adayı ve dokunulmamış zamansal değerlendirme

Ders: Samsung Innovation Campus — Pazarlamada Yapay Zekâ Bitirme Projesi

Ekip: Grup 7

Proje: GrowthPilot AI

Hazırlayan: Şahin Başcı

Tarih: 9 Eylül 2026

Durum: Nihai yerel akademik paket

YAPAY ZEKA KULLANIM BEYANI — Bu belge OpenAI Codex/ChatGPT desteğiyle hazırlanmış ve depo kanıtlarıyla kontrol edilmiştir. Proje ölçütleri yürütülmüş, sürümlenmiş eserlerden gelir; dış iddialar kaynaklandırılmıştır. İnsan incelemesi gereklidir.

Bölüm I — Model iyileştirme

1. İlk değerlendirme ve zayıflıklar

İlk keşif lojistik regresyonu doğrulama PR-AUC 0.805322 ile seçti. Zayıflıkları olasılık kalibrasyonu (Brier 0.213300; ECE 0.169377) ve düzenileştirme duyarlılığıydı. LightGBM PR-AUC'de çok yakındı ve ham kalibrasyonu daha iyiydi; bu nedenle iyileştirme, birincil seçim kuralını değiştirmeden üç öğrenilmiş aileyi karşılaştırdı.

2. İyileştirme teknikleri

- Lojistik ızgara: $C \in \{0.01, 0.05, 0.2, 1.0, 5.0\}$; sıralama, kalibrasyon ve kapasite doğrudan ölçüldüğünden sınıf ağırlığı kapalı tutuldu.
- Rastgele orman ızgarası: 400 ağaç, asgari yaprak $\{5,10,20\}$, azami derinlik $\{8,16\}$.
- LightGBM: öğrenme oranı, yaprak, derinlik, asgari alt örnek, L2, satır ve sütun alt örneklemeinde 12 tohumlu deneme.
- Sigmoid kalibrasyon yalnız 2011-06-01 anlık görüntüsünde uyarlandı.
- Operasyon eşiği yaklaşık %10 kalibrasyon kapasitesinde 0.812509305136 olarak sabitlendi.

3. Ayarlamanın etkisi

Aşama	PR-AUC	ROC-AUC	Brier	ECE	İlk %10 kesinlik / artış
İlk lojistik doğrulama	0.805322	0.782819	0.213300	0.169377	0.871642 / 1.510154
İyileştirilmiş lojistik C=.01	0.812223	0.787127	0.196710	0.106133	0.883582 / 1.530841
Kalibrasyon uyumu, betimsel	0.739014	0.773722	0.193632	0.040863	0.834586 / 1.671058


Kalibrasyon ölçütleri aynı kalibrasyon etiketlerini yeniden kullandığından betimseldir, tarafsız test tahmini değildir.

C değerinin 1.0'dan 0.01'e indirilmesi PR-AUC'yi 0.812223'e çıkarıp Brier'ı 0.196710'a düşürdü. Sonraki bölümde sigmoid kalibrasyon ECE'yi betimsel olarak 0.040863'e düşürdü. Seri hâle getirilmiş adayın sağlama toplamı 942d705d66a9469d57494626a99da83c91a9a895a3a2b2d7e977ff3ba56952ad'dir.

4. Çapraz doğrulama ve özellik seçimi

Rastgele k-katlı doğrulama, gelecek/geçmiş anlık görüntülerini ve tekrarlanan müşterileri karıştıracağı için kullanılmadı. Bunun yerine genişleyen kronolojik eğitim kesimleri ile ayrı doğrulama, kalibrasyon ve nihai test tarihleri kullanıldı. Test sonrası özellik seçimi yapılmadı: düzenlileştirilmiş lojistik hat katsayı büyüklüğünü sınırlar; testi gördükten sonra özellik kaldırmak dondurma kuralını ihlal eder.

5. Açıklanabilirlik doğrulaması



Şekil 1. Kalibre log-olasılıkta küresel ortalama mutlak SHAP katkısı. Projede üretilen tanı.

SHAP ayrıştırması dondurulmuş lojistik hat için kalibre log-olasılıkta hesaplandı. Azami toplamsallık hatası $8.881784197001252 \times 10^{-16}$ olup sayısal tutarlılığı doğrular. Katkılar model puanını açıklar; nedensel etki değildir ve desteklenmeyen kişisel iddialara dönüştürülemez.

Bölüm II — Nihai test

1. Test hazırlığı ve bütünlük

Nihai test, 2011-09-01 kesiminde tamamen gözlenen 90 günlük etiket penceresine sahip 2.772 müşteridir. Hazırlanmış dosyanın SHA-256 değeri 2830e4738acfee8c5561f5eb513874d0cacae32f3b3095c412db62dc2cf78ff6'dır. Erişimden önce aday bildirimi, ön işleme, kalibratör, sağlama toplamı ve eşik donduruldu. Test sonrası yeniden ayar yasaktır.


2. Model uygulaması

```
bundle = joblib.load('artifacts/models/final_candidate.joblib')
assert sha256_file(model_path) == EXPECTED_MODEL_SHA256
scores = bundle['calibrated_model'].predict_proba(X_test)[:, 1]
predicted = scores >= 0.812509305136
# Hedef, özellik ve bölme sürümleri raporlamadan önce denetlenir.
```

3. Nihai test ölçütleri

Ölçüt	Nihai test sonucu	%95 bootstrap aralığı
Satır / yaygınlık	2.772 / 0.392857	Uygulanamaz
PR-AUC	0.647525	[0.618131, 0.678937]
ROC-AUC	0.765878	[0.748534, 0.782761]
Brier skoru	0.199854	[0.192598, 0.207125]
Log kaybı	0.582761	Bootstrap uygulanmadı
ECE (10 kutu)	0.095054	Bootstrap uygulanmadı
İlk %10 kesinlik / duyarlılık / artış	0.748201 / 0.191001 / 1.904513	Bootstrap uygulanmadı

Kanıt sınıfı: projede yürütülen, dokunulmamış zamansal bekletme. Aralıklar bu kesim için parametrik olmayan satır bootstrap aralıklarıdır.



Şekil 2. Nihai zamansal testte kesinlik-duyarlılık ve olasılık kalibrasyonu.

4. Dondurulmuş eşik karışıklık matrisi

Gerçek / tahmin	Aktif tahmini	Hareketsiz tahmini
Gerçekte aktif	TN = 1.603	FP = 80
Gerçekte hareketsiz	FN = 867	TP = 222

0.812509305136 eşiği 302 müşteriyi (%10,8947) seçti: kesinlik 0.735099, duyarlılık 0.203857, F1 0.319195.

5. Doğrulamadan teste karşılaştırma

Bölüm	PR-AUC	ROC-AUC	Brier	Yaygınlık	Yorum
Doğrulama	0.812223	0.787127	0.196710	0.577187	Aile/ayar seçimi
Kalibrasyon	0.739014	0.773722	0.193632	0.499436	Sigmoid ve eşik; betimsel

Bölüm	PR-AUC	ROC-AUC	Brier	Yaygınlık	Yorum
Nihai test	0.647525	0.765878	0.199854	0.392857	Tek dokunulmamış zamansal bekletme

PR-AUC 0.812223'ten 0.647525'e, yaygınlık 0.577187'den 0.392857'ye iner. ROC-AUC 0.765878 kalırken ilk %10 artış 1.904513'e çıkar. Fark, dondurulmuş sonucu değiştirme gerekçesi değil, zamansal/veri kayması ve belirsizlik kanıtıdır.

6. Dağıtımın gerçek durumu

Eser yerelde growthpilot-churn-inactivity sürüm 1 ve champion takma adıyla kayıtlı, kiracı kapsamlı istek üzerine ve kalıcı toplu puanlamaya bağlıdır. “Champion” yerel kayıt takma adıdır, üretim dağıtım kanıtı değildir. İstek üzerine puanlama demo kapalıdır; canlı bulut, kiracı verisi sapması ve hizmet düzeyi doğrulanmamıştır. Hiçbir puan eylem yetkisi vermez.

7. Sonuç

Dondurulmuş model tarihsel testte, özellikle sınırlı erişim kapasitesinde yararlı sıralama sinyali verir; ancak katı eşikte çoğu hareketsiz müşteriye kaçırır. İnsan kararını desteklemeli, yerine geçmemelidir. Üretim için güncel kiracı verisi, hukuka uygun kullanım, kalibrasyon/sapma izleme ve nedensel kampanya değerlendirmesi gerekir.

Kaynakça ve kanıt

scikit-learn geliştiricileri. Olasılık kalibrasyonu ve model değerlendirme belgeleri. <https://scikit-learn.org/stable/modules/calibration.html>

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. NeurIPS 30. <https://arxiv.org/abs/1705.07874>

Proje kanıtları: artifacts/ml/final_candidate.json, final_evaluation.json/png, explanations.json/png, model_registry.json; scripts/refine_model.py, evaluate_final.py, explain_model.py ve register_model.py.